

Tianyi Zhang

404-422-2842 | tzhang708@gatech.edu | LinkedIn | GitHub | Google Scholar | 个人网站

教育背景

佐治亚理工学院
计算机科学硕士

美国佐治亚州亚特兰大
2025 年 8 月 - 2027 年 5 月

埃默里大学
定量科学理学学士

美国佐治亚州亚特兰大
2021 年 8 月 - 2025 年 5 月

专业经历

LinkedIn

机器学习工程师实习生

美国加利福尼亚州山景城
2026 年 5 月 - 2026 年 8 月

- 改进生产级双塔向量检索模型 (two-tower embedding retriever)，审计并修正停留时长主导的监督信号 (supervision)、缺失的拒绝反馈 (negative feedback)，以及未曝光负样本 (imputed negatives) 造成的评估偏差。
- 设计并交付兼顾线上成本的视觉语言模型教师 / 向量表征学生架构 (VLM-teacher / embedding-student)，将离线多模态软标签 (soft labels) 与硬负例 (hard negatives) 蒸馏为可预计算的近似最近邻 (ANN) 向量，供下游排序使用。
- 交付十亿级行为数据离线评估框架，按生命周期和信号强度构造匹配分组 (matched cohorts)，控制群体规模与候选池差异的混杂因素 (confounders)；通过覆盖率、互补性和主题多样性揭示相关性与内容广度的权衡。

佐治亚理工 EIC 实验室 · NVIDIA AI Research

学生研究员

美国佐治亚州亚特兰大
2025 年 7 月 - 2025 年 12 月

- 工程化 AgentSuite 智能体基准审计 (benchmark auditing) 流水线，构建基于分类体系的大模型裁判 (LLM-as-a-Judge) 和确定性结构检测器，在 6 个基准上与专家审计达到 0.79–0.87 F1。
- 无需重新调参即可泛化到未见基准；识别出约 23% 的任务存在有效性缺陷，修正后改变了 63% 的模型排名。

埃默里大学图挖掘实验室

机器学习研究员

美国佐治亚州亚特兰大
2023 年 12 月 - 2025 年 5 月

- 设计格兰杰因果有向无环图 (Granger-causal DAG) 框架，将 fMRI 时间序列转换为有向脑网络，揭示相关图无法表达的非对称依赖，并提升下游诊断预测。
- 共同开发脑网络状态 Transformer，将动态功能连接聚类为反复出现的潜在状态，并联合建模状态内与状态间结构以增强下游预测。

论文发表

H. Suh*, S. Lee*, B. Ji*, R. Khare, B. Khan, H. Kim, T. Zhang, et al. “AgentSuite: Toward More Reliable Agent Evaluation with a Component-Based Benchmark Auditing Pipeline.” *International Conference on Machine Learning (ICML)* 2026.

T. Zhang, K. Han, J. Nie, et al. “Causal Brain Connectivity: Integrating Granger Directed Graphs in fMRI Analysis.” *International Conference on Artificial Intelligence in Medicine (AIME)* 2025.

J. Nie, K. Han, T. Zhang, et al. “Brain Network State Transformer: Leveraging State Functional Connectivity.” *IEEE Engineering in Medicine and Biology Society (EMBC)* 2025. (Oral)

开源贡献

NVIDIA NeMo RL (2.0K stars)

已合并 PR  审阅中 PR 

开源贡献者 | 面向大语言模型强化学习 (RL) 与后训练 (post-training) 的高效可扩展工具包。

- 性能与正确性 (已合并): 优化对数概率 (log-probability) 与 top-k 蒸馏路径，使跨 token P-KL 提速 3.7×，并将每个张量并行进程 (rank) 的通信量从 250 MiB 降至 16 MiB。
- 多奖励 GDPO (审阅中): 在异步 rollout、replay、检查点恢复和自定义策略目标之间端到端保留命名奖励分量，支持可组合的多奖励后训练。
- SingleController PPO (审阅中): 流式传输 actor 与 critic minibatch，避免构造合并后的大 payload，在保持 H100 功能恢复与训练一致性的同时降低显存压力。

技术能力

编程语言

Python, Go, SQL, C/C++, Java, R

机器学习框架

PyTorch, TensorFlow, PyTorch Lightning, Hugging Face Transformers

后训练与推理

NVIDIA NeMo RL, verl, vLLM, SGLang, CUDA

数据与工程工具

PySpark, Apache Spark, Flyte, MLflow, FastAPI, Docker, AWS, GitHub Actions, Linux